Atividade 1 - Aprendizado Supervisionado (MO432/MC934)

Luís Antônio Almeida Lima Vieira
Instituto de Computação
Universidade Estadual de Campinas
l221045@dac.unicamp.br

I. Projeto Prático - Detecção de Fraude

A. Introdução

Neste projeto, foram construídos e avaliados modelos de classificação, aplicados ao problema de detecção de fraude em transações de cartão de crédito. Como fonte de dados para o problema, foi utilizada a base Credit Card Fraud Detection, disponível em [2], contendo transações feitas por cartões de crédito na Europa em 2013. Essa base de dados é composta por 492 casos de fraude em um total de 284.807 transações, o que representa um alto grau de desbalanceamento entre as classes do problema, sendo interessante para avaliar o desempenho de classificadores treinados em classes desbalanceadas, que é um problema muito comum em aplicações reais de Aprendizado de Máquina.

Com relação às variáveis utilizadas neste trabalho, estão disponíveis no dataset, 28 features obtidas por um processo de redução de dimensionalidade por PCA, extraídas de dados reais sobre transações financeiras. Além disso, há uma variável temporal e uma variável de quantidade (Amount), que representa o valor financeiro da transação. As classes estão identificadas como 1 para fraude e 0 caso contrário.

B. Metodologia

Primeiramente, foi realizada uma análise exploratória dos dados. Foi verificado o balanceamento dos dados entre as classes, que consistiu em 99.827% para a classe normal e apenas 0.173% para a classe fraude. Foram verificadas, também, as distribuições das features para ambas as classes, verificando um caráter próximo a distribuições normais, com diferenças evidentes entre as distribuições das classes. Vale destacar, também, a presença de outliers, principalmente na feature Amount, com valores chegando a 25691, sendo o valor médio em torno de 88.

Após esta análise, foi realizado um pré-processamento dos dados, que consistiu na verificação da presença de valores nulos ou não numéricos (não foram encontrados), seguido pela separação de 20% dos dados em um conjunto de testes, mantendo o balanceamento entre as classes, para avaliar os modelos treinados visando analisar a capacidade de generalização em um conjunto representativo. Por fim, os conjuntos obtidos foram escalonados separadamente (par evitar vazamentos de dados), por meio de um processo de padronização, subtraindo a média e dividindo pelo desvio padrão do respectivo conjunto.

Feito isso, partindo da mesma estrutura de dados, foram testadas duas abordagens de modelagem para a classificação dos dados. A primeira abordagem utilizada foi baseada na análise da fronteira de decisão de Modelos generativos, enquanto a segunda foi baseada em classificação supervisionada.

1) Abordagem 1: Modelagem da Classe Normal (Detecção de Anomalia).: Nesta abordagem, os dados da classe normal (não-fraudulenta) foram isolados e modelados por um modelo generativo probabilístico para descrever a distribução $P(x|C_{Normal})$. O modelo escolhido foi o de Gaussiana Multivariada, pois a Gaussiana permite capturar a correlação entre atributos, a estimativa de parâmetros é fácil via MLE, possui uma boa eficiência computacional, além de as features obtidas via PCA da classe normal possuirem um comportamento que se assemelha a Gausianas, o que é uma suposição neste modelo. Com isso, os parâmetros média (μ) e matriz de covariância (Σ) foram estimados via MLE para a classe não-fraudulenta. Com isso, foi calculada a distância de Mahalanobis ($\Delta_1^2 = (\boldsymbol{x}-\boldsymbol{\mu}_1)^T\Sigma_1^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_1)$) de todos os dados para esta distribuição gerada, servindo como score de anomalia.

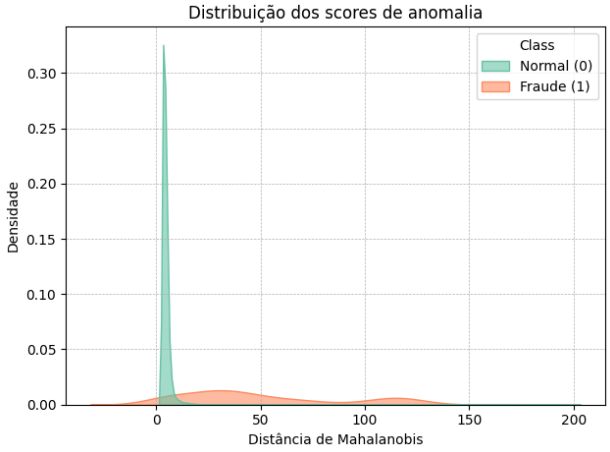

Fig. 1. Distribuição dos scores de anomalia para as classes fraude e não-fraude na abordagem 1.

Foi, então selecionado um limiar de score de anomalia para a classificação de um dado como fraudulento. Este limiar foi selecionado através da curva Precision-Recall (PR), de forma a buscar o limiar que maximiza o f1-score da classificação. Por

último, as distâncias de Mahalanobis foram calculadas para os dados de teste, e o limiar ótimo encontrado foi utilizado para classificar as amostras. O desempenho de classificação foi avaliado pelo cálculo da Precisão, Recall, f1-score para ambas as classes, além da matriz de confusão e AUC-PR.

2) Abordagem 2: Modelagem como Classificação Supervisionada:.: Nesta abordagem, foi escolhido um classificador por Regressão Logística como modelo de classificação probabilística, que gera como saída a probabilidade para a classe fraude ($P(C_{fraude}|x)$. Como forma de avaliar o desempenho do modelo para obter o limiar ótimo de classificação, foi utilizada a metodologia de dividir o conjunto de treinamento em dados para treino e dados para validação, quetem a função de avaliar a performance e generalização durante o treinamento. A metodologia utilizada foi o k-fold em 5 pastas. Para cada uma das pastas, foi encontrado o limiar de maior f1-score de validação, pela mesma metodologia item anterior. O limite escolhido, portanto, foi o limite de maior métrica de validação. Após obter o melhor limiar, o desempenho do modelo foi treinado nos dados de teste, com a mesma metodologia do item anterior.

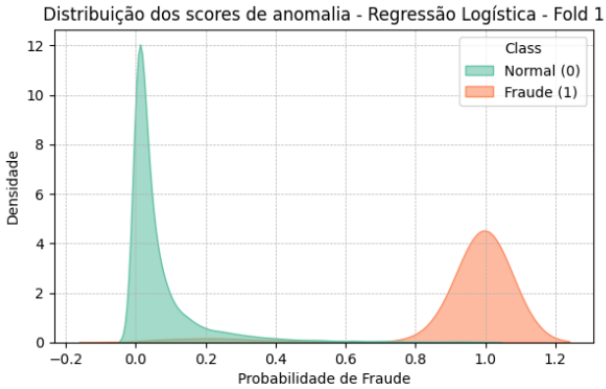

Fig. 2. Distribuição dos scores de anomalia para as classes fraude e não-fraude na abordagem 2.

C. Resultados

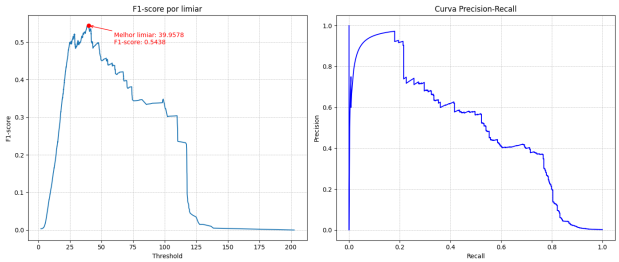

Fig. 3. Abordagem 1. f1-scores obtidos para cada limiar (à esquerda). Curva PR (à direita).

As Figuras 3 e 5 representam as distribuições dos *scores* de fraude obtidos pelos classificadores. As Figuras 3 e 5 também mostram o processo de escolha do limiar de classificação, assim como o f1-score no limiar ótimo. As

TABLE I
MÉTRICAS NO CONJUNTO DE TESTE OBTIDAS COM O MODELO GENERATIVO PROBABILÍSTICO.

Classe	Precisão	Recall	F1-Score
Normal (0)	1.00	1.00	1.00
Fraude (1)	0.53	0.53	0.53

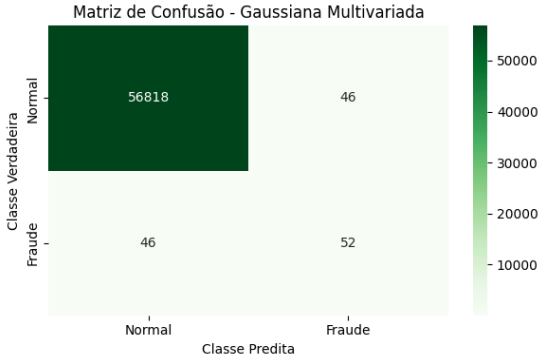

Fig. 4. Matriz de confusão para os dados de teste — abordagem 1.

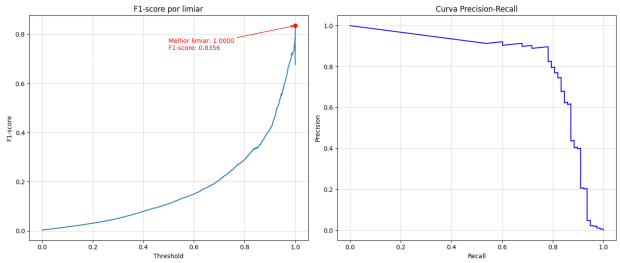

Fig. 5. Abordagem 2. f1-scores obtidos para cada limiar (à esquerda). Curva PR (à direita).

TABLE II
MÉTRICAS NO CONJUNTO DE TESTE OBTIDAS COM A REGRESSÃO LOGÍSTICA.

Classe	Precisão	Recall	F1-Score
Normal (0)	1.00	1.00	1.00
Fraude (1)	0.82	0.64	0.72

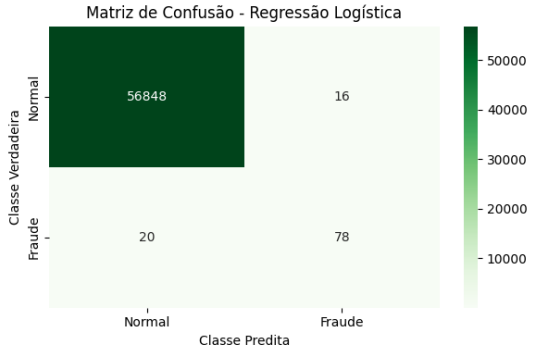

Fig. 6. Matriz de confusão para os dados de teste — abordagem 2 (regressão logística).

Tabelas I e II apresentam os resultados de desempenho no conjunto de testes para os dois modelos, e as Figuras 4 e 6 mostram as matrizes de confusão para ambos os casos. O valor de AUC-PR para o caso 1 foi de 0.5329, enquanto que pro caso 2 foi de 0.7420.

D. Conclusão

Ao comparar as abordagens 1 e 2, foi possível notar que o modelo de Regressão logística (abordagem 2) apresentou melhores desempenhos no conjunto de testes com relação a abordagem 1 (Detecção de Anomalia), obtendo um valor de área sob a curva PR (AUC-PR) de 0,742, indicando um melhor desempenho tanto em precision, quanto em Recall para classificar os dados de transações financeiras, com relação ao modelo generativo probabilístico, que apresentou AUC-PR com valor de 0.532. O mesmo se observou nas métricas durante a escolha do limiar ótimo, com um f1-score de 0.82 para o modelo de Regressão logística e 0.54 para o modelo por gaussiana multivariada.

Com relação ao modelo de gaussiana multivariada, este tem uma limitação importante de assumir que os dados apresentam distribuição próxima da Gaussiana. Além disso, é um modelo simples, com menor precisão de desempenho. Por outro lado, este modelo tem a vantagem de não necessitar diretamente de rótulos, podendo ser aplicado em um contexto semi-supervisionado, além de possuir a possibilidade de classificar mesmo com poucos dados de treino.

Com relação ao modelo de Regressão logística, este possui vantagens por aprender diretamente por padrões e conseguir apresentar um desempenho bom mesmo neste contexto de um grande desbalanceamento. apresentando melhores desempenhos.

Com relação à escolha dos limiares de classificação, estes influenciam no balanço entre precision e recall, e muitas vezes a escolha vai depender do contexto específico ao priorizar mais não perder casos de fraude ou permitir perder alguns casos em que não há muita certeza na classificação.

II. Exercícios Teórico-Conceituais

*A. **Exercício 1: Análise da Fronteira de Decisão em Modelos Generativos***

1) Gaussianas multivariadas: Resposta:

Segundo a sessão 4.2 de [1], referente a modelos generativos probabilísticos, modelamos as classes por densidades condicionais de classe $p(x|C_k)$, assim como as probabilidades à priori das classes $p(C_k)$, e assim computar as probabilidades à posteriori $p(C_k|x)$ pelo teorema de Bayes. Para duas classes:

$$\begin{aligned} p(C_1|x) &= \frac{p(x|C_1)\,p(C_1)}{p(x|C_1)\,p(C_1) + p(x|C_2)\,p(C_2)} \\ &= \frac{1}{1+\exp(-a)} \\ &= \sigma(a) \end{aligned}$$

Onde, $\sigma(a)$ é a função sigmóide logística e,

$$a = \ln\left(\frac{p(x|C_1)\,p(C_1)}{p(x|C_2)\,p(C_2)}\right)$$

Como $p(C_1) = p(C_2) = 0.5$, a pode ser expressa como:

$$\begin{aligned} a &= \ln\left(\frac{p(x|C_1)\,p(C_1)}{p(x|C_2)\,p(C_2)}\right) \\ &= \ln\left(\frac{p(x|C_1)}{p(x|C_2)}\right) \end{aligned}$$

Sabemos que $p(x|C_k)$, é uma Gaussiana Multivariada:

$$p(x|C_k) = \mathcal{N}(x|\mu_k, \Sigma_k)$$

Substituindo na expressão de a:

$$\begin{aligned} a &= \ln\left(\frac{\frac{1}{|\Sigma_1|^{1/2}}\exp\left(-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_1)^T\Sigma_1^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_1)\right)}{\frac{1}{|\Sigma_2|^{1/2}}\exp\left(-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_2)^T\Sigma_2^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_2)\right)}\right) \\ a &= \ln\left(\frac{1}{|\Sigma_1|^{1/2}}\right) - \ln\left(\frac{1}{|\Sigma_2|^{1/2}}\right) \\ &+ -\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_1)^T\Sigma_1^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_1) \\ &+ \frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_2)^T\Sigma_2^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_2) \end{aligned}$$

Na fronteira de decisão, a tem valor zero, logo:

$$\begin{aligned} \ln\left(\frac{|\Sigma_2|}{|\Sigma_1|}\right) &= -(\boldsymbol{x}-\boldsymbol{\mu}_2)^T\Sigma_2^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_2) \\ &+ (\boldsymbol{x}-\boldsymbol{\mu}_1)^T\Sigma_1^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_1) \end{aligned}$$

Portanto, a fronteira de decisão contém termos quadráticos em $\boldsymbol{x}$, logo a fronteira tem uma forma geométrica quadrática, ou seja, não linear no caso geral em que $\Sigma_1 \neq \Sigma_2$.

2) Agora, assuma priors $p(C_1) = \pi$, $p(C_2) = 1 - \pi$ e covariâncias compartilhadas $\Sigma_1 = \Sigma_2 = \Sigma$. : Resposta:

Partindo da equação

$$a = \ln\left(\frac{p(x|C_1)\,p(C_1)}{p(x|C_2)\,p(C_2)}\right)$$

Temos que:

$$a = \ln p(x|C_1) - \ln p(x|C_2) + \ln\left(\frac{p(C_1)}{p(C_2)}\right)$$

Como $p(x|C_k)$, são Gaussianas Multivariadas:

$$a = \ln\mathcal{N}(x \mid \boldsymbol{\mu}_1, \Sigma_1) - \ln\mathcal{N}(x \mid \boldsymbol{\mu}_2, \Sigma_2) + \ln\left(\frac{p(C_1)}{p(C_2)}\right)$$

Logo:

$$
\begin{aligned}
a = & -\frac{1}{2}\ln|\Sigma_1| - \frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_1)^T\Sigma_1^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_1) \\
& + \frac{1}{2}\ln|\Sigma_2| + \frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_2)^T\Sigma_2^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_2) \\
& + \ln\left(\frac{p(C_1)}{p(C_2)}\right)
\end{aligned}
$$

Como na questão anterior, na fronteira de decisão a tem valor 0. Como $\Sigma_1 = \Sigma_2 = \Sigma$, os termos que contém o logarítmo da matriz de covariância são iguais e são cancelados na expressão. Logo

$$
\begin{aligned}
\ln\left(\frac{p(C_1)}{p(C_2)}\right) = & \frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_1)^T\Sigma_1^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_1) \\
& - \frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_2)^T\Sigma_2^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_2)
\end{aligned}
$$

Como $p(C_1) = \pi$, $p(C_2) = 1 - \pi$, temos:

$$
\begin{aligned}
\ln\left(\frac{\pi}{1-\pi}\right) = & \frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_1)^T\Sigma_1^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_1) \\
& - \frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_2)^T\Sigma_2^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_2)
\end{aligned}
$$

Portanto, neste caso, a fronteira de decisão passa a ser linear, como mostra a equação acima. Além disso, percebe-se que neste caso o termo definido por $p(C_1) = \pi$ e $p(C_2) = 1 - \pi$ terá valor constante, definindo o viés da fronteira de decisão.

3) Distância de Mahalanobis: Resposta:

Considerando as classes normal (C_1) e fraude (C_2) modeladas como distribuições Gaussianas multivariadas, a distância de Mahalanobis pode ser usada para classificar um dado $\boldsymbol{x}$ com base na menor distância em relação aos centros das distribuições (ou seja, às médias $\boldsymbol{\mu}_1$ e $\boldsymbol{\mu}_2$), levando em conta suas respectivas covariâncias Σ_1 e Σ_2. A regra de decisão consiste em atribuir $\boldsymbol{x}$ à classe C_k que minimiza a fórmula da distância de Mahalanobis mostrada no enunciado. Este método, porém, assume algumas premissas como a de que as classes podem ser modeladas como Gaussianas multivariadas, além de as probabilidades a priori $p(C_1)$ e $p(C_2)$ serem conhecidas ou iguais. No caso delas serem iguais, há uma fronteira de decisão quadrática, como mostra o item 1. Outra premissa se baseia no caso de $\Sigma_1 = \Sigma_2$, em que a fronteira de decisão é linear, como mostra o item 2.

B. Exercício 2: Verossimilhanca, Entropia Cruzada e Regressão Logística

1) Função de verossimilhança (likelihood) e Regressão Logística: Resposta:

Para um classificador binário por Regressão Logística, com classes alvo $t_n \in \{0, 1\}$, a função de verossimilhança (likelihood) é dada por:

$$
\mathcal{L}(\mathbf{w}) = \prod_{n=1}^{N} p(t_n \mid \mathbf{w}) = \prod_{n=1}^{N} y_n^{t_n}(1-y_n)^{1-t_n}
$$

sendo y_n a saída do classificador para a n-ésima observação, equivalente à probabilidade prevista para a classe positiva ($t_n = 1$) dado os dados de entrada x_n e os parâmetros do modelo w. N representa o número total de observações. Para facilitar cálculos computacionais, é aplicado o logarítmo da função de verossimilhança, com isso, temos:

$$
\ln\mathcal{L}(\mathbf{w}) = \ln\prod_{n=1}^{N} y_n^{t_n}(1-y_n)^{1-t_n}
$$

$$
\ln\mathcal{L}(\mathbf{w}) = \sum_{n=1}^{N}\left[t_n\ln y_n + (1-t_n)\ln(1-y_n)\right]
$$

Essa última equação equivale ao negativo da função de erro da entropia cruzada:

$$
E(\mathbf{w}) = -\sum_{n=1}^{N}\left[t_n\ln y_n + (1-t_n)\ln(1-y_n)\right]
$$

Portanto ao maximizar a função de verossimilhanca é equivalente a minimizar a função de erro da entropia cruzada.

2) Derive o gradiente $\nabla E(\mathbf{w})$: Resposta:

A função de erro (entropia cruzada) para regressão logística é dada por:

$$
E(\mathbf{w}) = -\sum_{n=1}^{N}\left[t_n\ln y_n + (1-t_n)\ln(1-y_n)\right],
$$

onde $y_n = \sigma(z) = \frac{1}{1+e^{-z}}$ (função sigmóide) e $z = \mathbf{w}^T\boldsymbol{\phi}_n$. Para derivar o gradiente de $E(\mathbf{w})$ em relação a $\mathbf{w}$, utiliza-se a regra da cadeia:

$$
\frac{\partial E_n}{\partial w_j} = \frac{\partial E}{\partial y_n}\cdot\frac{\partial y_n}{\partial z_n}\cdot\frac{\partial z_n}{\partial w_j}
$$

Para o primeiro componente $\frac{\partial E_n}{\partial y_n}$:

$$
\frac{\partial E_n}{\partial y_n} = -\left(\frac{t_n}{y_n} - \frac{1-t_n}{1-y_n}\right)
$$

Para o segundo componente $\frac{\partial y_n}{\partial z_n}$:

$$
\frac{\partial y_n}{\partial z_n} = \sigma(z_n)(1-\sigma(z_n)) = y_n(1-y_n)
$$

Para o terceiro componente $\frac{\partial z_n}{\partial w_j}$:

$$
\frac{\partial z_n}{\partial w_j} = \phi_{n,j}
$$

Substituindo os componentes na equação de $\frac{\partial E_n}{\partial w_j}$:

$$
\frac{\partial E_n}{\partial w_j} = -\left(\frac{t_n}{y_n} - \frac{1-t_n}{1-y_n}\right)\cdot y_n(1-y_n)\cdot\phi_{n,j}
$$

Reorganizando os termos e simplificando a expressão, temos:

$$\frac{\partial E_n}{\partial w_j} = (y_n - t_n) \cdot \phi_{n,j}$$

Logo:

$$\nabla E(\mathbf{w}) = \sum_{n=1}^{N} (y_n - t_n)\boldsymbol{\phi}_n$$

A função de entropia cruzada, portanto, possui o resultado da aplicação de gradiente se apresentando como uma expressão de forma simples, como demonstrado anteriormente. Essa expressão é muito eficiente de se computar vetorialmente, sendo conveniente em algoritmos de computador que otimizam os pesos por meio da aplicação de gradiente.

3) Overfitting na Regressão Logística: Resposta:

O problema do sobreajuste (overfitting) ocorre quando o modelo se torna extremamente ajustado aos dados de treinamento, não sendo capaz de generalizar o seu desempenho para dados que não foram incluídos no treinamento. Quando os dados são linearmente separáveis, há no espaço de características $\boldsymbol{\phi}$ dos dados um hiperplano que separa as classes perfeitamente. Neste caso, ao otimizar os pesos $\mathbf{w}$ do modelo de Regressão Logística maximizando a função de Verossimilhança através dos dados de treino, estes pesos tenderão a crescer muito em módulo, empurrando as probabilidades y_n da saída do modelo para valores muito próximos dos targets das classes. Neste caso, o modelo se torna extremamente ajustado para os dados de treino, caracterizando overfitting. Com a regularização L_2 (Ridge), há a adição de um termo na função de máxima verossimilhança que penaliza esse score para um grande crescimento dos pesos em módulo, limitando o crescimento de $\|\mathbf{w}\|$, forçando o modelo a encontrar um hiperplano não tão ajustado aos dados de treino, sendo capaz de generalizar.

C. *Decomposição Bias-Variância (Teórico e Prático)*

1) Explique conceitualmente os termos $(bias)^2$, variância (variance) e ruído (noise) na decomposição do erro quadrático esperado:erro esperado $= (bias)^2 +$ variância $+$ ruído. Como a complexidade do modelo (e.g., grau de um polinômio, k no k-NN, ou λ na regularização Ridge) tipicamente afeta o bias e a variância?: Resposta:

A decomposição do erro quadrático separa o erro esperado em três componentes: viés (bias), variância e ruído. O **bias** mede a distância das previsões médias do modelo para os valores esperados. Portando um alto viés representa um modelo que ainda está longe de aprender padrões dos dados, representando um subajuste (underfitting). A **variância** mede a sensibilidade das predições do modelo a pequenas flutuações do nos dados. Um modelo com alta variância é muito sensível aos detalhes dos dados, especificando demais aos dados de treinamento e caracterizando um sobreajuste (overfitting), comprometendo a capacidade de generalização. Por fim, o **ruído** representa o componente aleatório dos dados, ou seja, variáveis ocultas que não são capturadas pelo modelo.

A complexidade do modelo está ligada ao viés e a variância. Em modelos mais simples, há a tendência de valores de viés mais elevados e baixa variância, ou seja, não conseguem aprender relações complexas mas não são sensíveis à pequenas variações. Por outro lado, modelos mais complexos apresentam um baixo viés, ajustando bem para dados complexos, porém apresentam alta variância prejudicando a generalização. Esse dilema viés-variância, portanto deve ser pesado corretamente ao modelar problemas de Machine Learning a depender do tipo de problema.

*2) **(Componente Prático)**:* Resposta:

Para esta questão, foi gerado um dataset com dados sintéticos utilizando a função geradora $f(x) = cos(4\pi x)$. Um conjunto de testes para o modelo foi gerado com a aplicação da própria função geradora em 100 pontos de dados. Após isso, foram gerados 100 conjuntos de treinamento com a adição de ruído Gaussiano aleatório (com desvio padrão de 0.3) na função e aplicação desta em amostras aleatórias (x de treino). A partir destas amostras foram treinados regressores lineares de grau 5 com regularização Ridge, e avaliados no conjunto de testes para medir o impacto dos valores do coeficiente de regularização λ, variando, assim, a complexidade dos modelos.

*3) **(Componente Prático)**:* Resposta:

Como mencionado no item anterior, foi utilizada a estratégia de repetidas divisões entre treino e teste, com objetivo de empiricamente observar o comportamento do viés e variância com base na variação da complexidade do modelo. Primeiramente, foi utilizado um coeficiente de regularização elevado, indicando que há uma grande limitação para o crescimento dos pesos no treinamento, produzindo uma variância baixa e um viés elevado (sobajuste), como mostra a Fig. X.

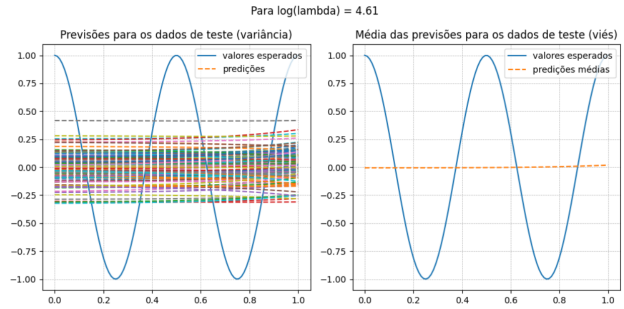

Fig. 7. Visualização do $(bias)^2$ e da variância em função da para um modelo com alta regularização.

Após isso, foi utilizado um coeficiente de regularização baixo, que limita pouco o crescimento dos pesos, produzindo

uma variância elevada (sensível à variações nos dados) e um viés baixo, caracterizando um sobreajuste nos dados de treinamento, como mostra a Fig X.

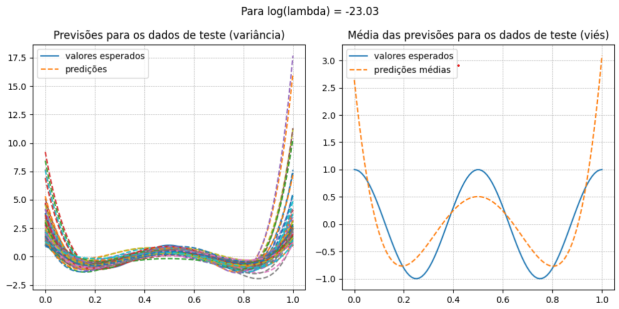

Fig. 8. Visualização do $(bias)^2$ e da variância em função da para um modelo com baixa regularização.

Para a visualização do comportamento do $bias^2$ e variância com a mudança do valor de regularização, o $bias^2$ foi calculado pelo erro quadrático médio entre a média das predições para os dados de teste e o valor esperado de teste, enquanto a variância foi calculada pela média da variância das predições para os dados de teste. A curva de Erro ($E = bias^2 + variancia$) também foi obtida, como mostra a Fig X. Nela é possível visualizar o trade-off, seguindo os conceitos teóricos.

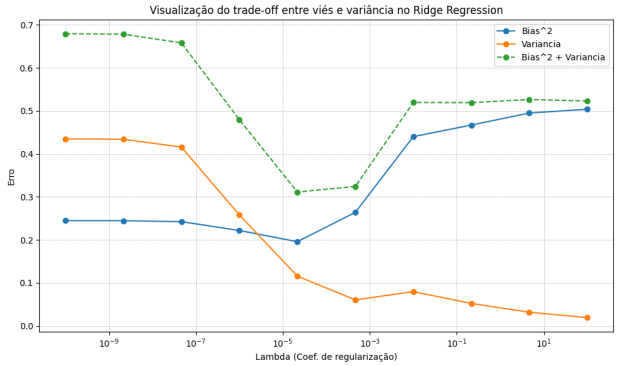

Fig. 9. Visualização do $(bias)^2$ e da variância para diferentes complexidades do modelo.

D. *Exercício 4: Avaliação de Classificação em Dados Desbalanceados*

1) Problemas da acurácia: Resposta

Para dados tipicamente desbalanceados, como é o caso de detecção de fraude, a acurácia não é uma métrica adequada para avaliação da performance de modelos. Esta métrica apenas mede a taxa de acerto, ou seja, quantas classificações foram corretas com relação ao total de classificações. Neste caso, considerando a grande maioria dos dados sendo de uma classe específica, uma taxa de acerto elevada para esta classe dominante reflete em uma acurácia elevada, mesmo que a classe que possui poucas amostras possua baixo desempenho de classificação.

2) Defina Precisão, Recall e F1-Score: Resposta

No contexto de avaliação de classificação, quatro conceitos são essenciais para o entendimento dessas métricas. O primeiro é o de **Verdadeiros positivos (TP)**, que representa a quantidade de dados da classe positiva (fraudulenta no caso de estudo) classificados corretamente. O segundo consiste em **Verdadeiros negativos (TN)**, que representa a quantidade de amostras da classe negativa (normal neste caso de estudo) classificadas corretamente. Já os **Falsos negativos (FN)** representam o número de amostras que deveriam ser classificadas na classe positiva, mas foram classificadas para a classe negativa, enquanto os **Falsos positivos (FP)** representam os dados classificados como da classe positiva mas que deveriam ser classificados para a classe negativa.

A **Precisão (Precision)** calcula a quantidade de verdadeiros positivos com relação à todas as classificações positivas, como mostra na equação abaixo.

$$Precision = \frac{TP}{TP + FP}$$

No caso do problema de transações fraudulentas, a precisão mede a taxa de acerto de todas as predições que retornaram fraude, portanto uma precisão alta representa que há poucos resultados falso positivos na classe fraude.

O **Recall** calcula a quantidade de verdadeiros positivos com relação à todas as classificações que deveriam ser dadas para a classe positiva, como mostra a equação abaixo.

$$Recall = \frac{TP}{TP + FN}$$

No caso do problema estudado, o Recall mede a proporção de fraudes corretamente classificadas, portando um Recall elevado representa que há poucos resultados falso negativos para a classe fraude. Por último, o **F1-Score** é apenas a média harmônica entre a Precisão e o Recall, medindo o equilíbrio entre essas métricas, como mostra a equação abaixo.

$$F1 - Score = \frac{2 * Precision * Recall}{Precision + Recall}$$

Em situações práticas, portanto seria interessate priorizar o Recall quando o custo de deixar passar uma fraude é elevado, evitando perder detecções, enquanto a precisão seria priorizada quando o custo de investigar falso positivos é muito elevado, por exemplo para evitar contatos com clientes dados como fraudulentos para investigação.

3) AUC-PR: Resposta:

A curva Precisão-Recall (PR), é obtida variando os limiares do modelo probabilístico para a classificação, ou seja, os valores de $p(C_{\text{fraude}}|x)$ mínimos para serem classificados como fraude. Para cada um desses limiares os valores de Precisão e Recall são obtidos com base nas classes preditas e nos rótulos verdadeiros. A área Sob a curva PR (AUC-PR) é a média ponderada da Precisão em todos os níveis

de recall, sumarizando o conteúdo da curva. Para datasets muito desbalanceados, a AUC-PR é preferível com relação a curva ROC, pois essa última avalia a taxa de falsos positivos, que pode parecer pequena pela quantidade grande de dados da classe negativa (normal), dando uma impressão errada de sucesso do classificador. Enquanto isso, a AUC-PR, tem seu foco na classe positiva (minoritária), por penalizar fortemente os casos Falso negativos, representando melhor o desempenho de classificação na classe minoritária.

REFERENCES

[1] Bishop, Christopher M., and Nasser M. Nasrabadi. Pattern recognition and machine learning. Vol. 4. No. 4. New York: springer, 2006.

[2] Université Libre de Bruxelles. Credit Card Fraud Detection. Kaggle, 2019. Disponível em https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud